贺逸杰

+86 15999591553 | henob22@gmail.com

2027 届 | AI Infra / 高性能计算

教育经历

加州大学圣地亚哥分校（UC San Diego）| 计算机工程 硕士 2025.09 – 2027.05

加州大学圣地亚哥分校（UC San Diego）| 计算机工程 本科 2021.09 – 2025.06

实习经历

字节跳动 | AML 异构硬件 | AI Infra 实习生 2026.06 – 2026.10

负责 Seedance 2.0/2.5 在 AMD GPU 上的核心算子适配与性能优化。

- 提出算法创新，结合 **VSA 与 Sol Attention** 设计再稀疏化方案，在选中块内区分精确计算与摘要近似；实现 INT8 QK / FP8 PV HIP Kernel 及摘要生成、二次分区路由，优化访存复用与分区流水线，减少 Attention 计算和预处理开销。相比 VSA 算子获得 **1.82x** 的加速，且**输出视频质量无任何劣化**。
- 针对不同卷积形状优化 **Conv1D 计算路径与分发策略**，融合布局/精度转换、缓存预打包权重，并按步长分解转置卷积以跳过无效计算；目标负载性能**较 MIOpen 提升约 32%**，消除 solution 切换引入的输出差异，保证**相同输入下输出逐位一致**。
- 基于 HIP/CK 优化 **Conv2D**，按输出通道数与空间尺寸调整分块，结合向量化布局转换、权重预打包及目标布局直接写回，减少数据搬运与独立输出转换；目标负载性能**较 MIOpen 提升约 20%**，并同样消除 solution 切换引入的输出差异。
- 开发 **All-to-All MoE 通信计算融合算子**，通过分块流水线、异步执行与三级缓冲实现通算重叠，改善 L2 缓存复用；在目标 SP8 配置下较原实现取得 **1.84× 加速**。

高通 Qualcomm | 软件工程实习生 2025.06 – 2025.09

- 负责高通自研端侧 GPU 上 **FlashAttention-2** 的底层移植与性能调优，针对端侧长序列推理调整分块策略、访存方式和局部缓存复用，减少重复数据读取、缓解访存瓶颈，并结合底层汇编指令消除寄存器溢出，相较原实现在同样目标工作负载下**吞吐量提升 34%**。
- 使用内部 **Profiler 与硬件打点分析 Kernel 性能瓶颈**，结合访存行为确定调优方向，指导底层代码迭代；在端侧对比优化前后的执行性能，验证特化实现的实际加速效果。

技术项目

AMD 算子优化 Agent | 个人开发 2026.08 – 至今

- 独立开发 **HIP/ROCm 算子优化工作流程**，以预设 benchmark contract 约束代码生成、验证、profiling 与监督审查，利用编译、运行及性能反馈驱动下一轮优化；构建 AMD 硬件知识库与瓶颈调优规则，支持跨架构适配。
- 在 MoE、卷积与 VSA 场景验证流程：将 MoE 算子迁移至 **MI300X**，性能超越官方实现 **10%**；VSA 较内部已优化实现取得 **1.08× 加速**，项目持续迭代中。

vLLM-Omni 多模态推理实践与框架优化 | vLLM-Omni 2026.09 – 至今

- 基于 vLLM-Omni 在 AMD GPU 上完成 MiniMax H3 部署，并修复多副本配置被回退逻辑忽略的问题；实现了**工作量感知路由及请求负载预留、释放与异常回滚**，在相同双四卡拓扑的长短请求混合测试中，**端到端提升有效吞吐 11.44%**。
- 参考 Sol-H3 设计，实现 **QKV 合并交换及 QKNorm/RoPE 与发送布局融合**，减少通信调用和中间张量读写；融合路径在固定形状下较原计算与打包路径实现 **3.19× 加速**，
- 完成运行中**取消机制的适配与优化**，通过共享内存信号与跨 rank 一致退出终止无效计算，**并修复音频解码非确定性问题**；八卡 25% 请求早期取消测试中，有效请求**全部完成耗时降低 21%，验证音视频输出一致**。

大模型核心算子复现与低精度优化 | CUDA / Triton 2026.02 – 2026.03

- 编写与复现 **Grouped GEMM、FlashAttention-2**；基于 CUTLASS 排查并解决 **RTX 5090 上 NVFP4 GEMM** 的适配问题，调整数据布局与计算路径。实现 CUDA 位操作 **FP4 编解码与工作区预分配**，启用 Tensor Core/TMA 加速路径，在目标测试负载下较 BF16 基线取得约 **2× 加速**。

专业技能

编程语言：C/C++、Python；CUDA、HIP/ROCm、Triton、OpenCL、System Verilog

框架与工具：PyTorch、vLLM、SGLang、Linux、Docker、Git、

工程方向：高性能计算，GPU 算子开发，推理引擎加速优化